

4인 고스톱에서의 위험 민감 LLM 평가

Risk-Sensitive LLM Evaluation in Four-Player Go-Stop

Go-Stop AI Evaluation Harness

Repository: <https://github.com/parktaejun-dev/ai-test-with-gostop>

Web: <https://godori.dahanda.dev/dashboard/paper.html>

한국어

초록

이 원고는 재현 가능한 4인 고스톱 하네스에서 고정 원격 LLM 정책을 평가한다. 고스톱은 숨은 정보, 확률적 드로우, 조합적 점수 계산, 다중 에이전트 상호작용, 고/스톱 위험 결정을 짧은 에피소드 안에 압축한다. 주 실험인 Qwen 패널과 NVIDIA 패널은 관측 성능이 파라미터 규모만으로 설명되지 않음을 보인다. 보조 실험은 제한된 조건에서 소형 모델도 양의 평균 수익을 낼 수 있고, 정책 framing 효과가 모델별로 다르게 나타남을 보여준다. 모든 결과는 기술통계이며 보편적 모델 순위가 아니다.

왜 고스톱인가?

고스톱은 작은 확률적 의사결정 환경이다. 각 행동은 숨은 패, 불확실한 미래 드로우, 상대 행동, 큰 하방 손실을 만들 수 있는 정산 규칙 아래에서 선택된다. 고/스톱 결정은 위험 민감적 stopping problem이다.

평균 수익만 보면 위험하다. 이 평가는 CVaR 5%, 승률, 파산 확률, 표본 수를 함께 본다.

산업적 연결: 광고 입찰

광고 입찰은 고스톱과 같은 게임이 아니지만, 평가해야 하는 의사결정 구조가 닮아 있다. 광고 시스템은 제한된 예산 안에서 매 노출마다 입찰할지, 낮출지, 기다릴지를 결정한다. 전환 확률, 경쟁 입찰가, 빈도 피로, 잔여 예산, 캠페인 pacing은 모두 불확실하다.

어떤 정책은 평균 ROAS가 좋아 보여도 특정 구간에서 예산을 너무 빨리 태우거나, 낮은 품질 inventory에 과도하게 노출되거나, 드문 큰 손실을 만들 수 있다. 본 논문의 고스톱 평가는 광고 시스템을 직접 모사하지 않는다. 대신 순차 행동 선택, 불확실성, 예산/위험 trade-off, 하방 위험 관리가 함께 나타나는 정책 평가 프레임으로 연결된다.

연구문제와 답

RQ1: 고스톱은 LLM 에이전트의 위험 민감적 순차 의사결정을 평가하기에 타당한 환경인가? 답은 방법론적으로 긍정적이다.

RQ2: Qwen/DashScope 패널에서 관측 성능은 명목 파라미터 규모에 대해 단조적인가? 답은 기술적으로 부정적이다.

RQ3: 비슷한 규모의 NVIDIA Build 패널에서 모델 family별 기술통계 차이가 보이는가? 제한된 패널 안에서 차이가 관찰된다.

RQ4: 보조 실험에서 소형 모델과 prompt-policy 변형은 측정 가능한 모델별 차이를 보이는가? 탐색적으로 그렇다.

용어 정의

Mean profit: 세션 종료 후 모델이 얻은 평균 수익이다. 평균만으로는 큰 손실 위험을 설명하지 못한다.

CVaR 5%: 가장 나쁜 하위 5% 결과의 평균 손실을 요약하는 하방 위험 지표다. 이 논문에서는 표본 수가 작으므로 확증 지표가 아니라 기술통계로 사용한다.

Win rate: 세션에서 양의 수익을 낸 비율이다. 승률이 높아도 큰 손실이 있으면 좋은 정책이라고 보기 어렵다.

Ruin probability: 자본이 소진되거나 사실상 파산 상태에 도달할 확률이다.

Parameter scale: 모델의 명목 파라미터 규모다. MoE 모델에서는 전체 파라미터와 active parameter가 다를 수 있다.

Policy framing: 같은 게임 상태에서 모델에 제시하는 의사결정 지침의 성향이다.

ROAS: 광고비 대비 매출이다. 평균 ROAS가 좋아도 예산 소진 속도나 하방 손실을 따로 봐야 한다.

Budget pacing: 캠페인 예산을 기간 전체에 맞게 쓰도록 지출 속도를 조절하는 과정이다.

네 가지 정책 framing 쉽게 설명

Balanced: 수익과 위험을 같이 보라는 기본형이다. 너무 무리하지도, 너무 겁먹지도 않는 정책이다.

Analytic: 패의 조합, 기대값, 상대 위험을 더 따져 보라는 분석형이다. 감보다 근거를 더 요구한다.

Conservative: 큰 손실을 피하는 것을 우선하는 보수형이다. 애매하면 멈추고, 자본을 지키는 쪽으로 기운다.

Aggressive: 수익 기회를 더 강하게 잡는 공격형이다. 이길 가능성이 보이면 더 밀어붙이는 쪽으로 기운다.

결과

모델	규모	평균 수익	CVaR 5%	승률	표본
qwen3.5-397b-a17b	397B/A17B	996.25	-1850.08	0.3021	48
qwen3.5-122b-a10b	122B/A10B	-51.75	-4145.33	0.3542	48
qwen3-coder-480b-a35b-instruct	480B/A35B	-198.92	-5084.75	0.2396	48
qwen3-coder-30b-a3b-instruct	30B/A3B	-745.58	-5269.25	0.1042	48

모델	규모	평균 수익	CVaR 5%	승률	표본
nvidia/nemotron-3-super-120b-a12b	~120B	500.65	-1384.17	0.2708	48
mistralai/mistral-small-4-119b-2603	~119B	-73.19	-4150.00	0.2917	48
qwen/qwen3.5-122b-a10b	122B	-172.85	-3350.42	0.1875	48
stockmark/stockmark-2-100b-instruct	~100B	-254.60	-4267.08	0.2500	48

소형 모델	규모	평균 수익	CVaR 5%	승률	표본
ibm/granite-3.0-3b-a800m-instruct	3B/A800M	381.25	-1966.67	0.3125	48
meta/llama-3.2-1b-instruct	1B	-20.83	-2083.33	0.2708	48
google/gemma-2-2b-it	2B	-68.75	-3833.33	0.2500	48
microsoft/phi-4-mini-instruct	mini	-291.67	-3916.67	0.1667	48

정책	Qwen 1위 모델	1위 평균	1위 CVaR
균형	qwen3-4b	224.88	-1166.67
분석	qwen3-4b	412.33	-2566.83
보수	qwen3-8b	238.08	-1301.67
공격	qwen3-14b	254.08	-1284.33

정책	NVIDIA 1위 모델	1위 평균	1위 CVaR
균형	nvidia/nemotron-3-super-120b-a12b	645.17	-2067.00
분석	nvidia/nemotron-3-super-120b-a12b	598.92	-2067.00

정책	NVIDIA 1위 모델	1위 평균	1위 CVaR
보수	nvidia/nemotron-3-super-120b-a12b	416.67	-1850.00
공격	nvidia/nemotron-3-super-120b-a12b	598.83	-3701.67

이 연구가 의미 있는가?

의미는 있다. 하지만 어떤 모델이 세계적으로 제일 고스톱을 잘한다는 논문은 아니다. 더 정확히는, 고스톱을 이용해 LLM의 순차 의사결정, 위험 관리, 모델 규모 효과, 모델 family 차이, prompt-policy 민감도를 한 번에 볼 수 있는 평가 하네스를 만든 연구다.

논문으로 쓸 수 있는 지점은 세 가지다. 첫째, 고스톱이 숨은 정보와 하방 위험을 함께 가진 짧은 평가 환경이라는 점이다. 둘째, Qwen 패널에서 성능이 파라미터 규모에 따라 단순히 증가하지 않았다는 점이다. 셋째, 같은 규모대 NVIDIA 패널과 정책 framing 실험에서 모델별 차이가 실제로 관찰됐다는 점이다.

약한 지점도 분명하다. 표본 수가 크지 않고, NVIDIA 실험은 호출 1회 제약이 있으며, Qwen 규모 비교는 Coder와 Qwen3.5 변형이 섞여 있다. 따라서 결론은 확정적 모델 순위가 아니라 재현 가능한 탐색적 평가와 방법론적 근거로 써야 한다.

한계

모델 패널은 사용 가능한 원격 API에서 구성한 convenience sample이다. Qwen 비교는 Coder와 Qwen3.5 변형을 함께 포함하므로 파라미터 규모와 특화 목적이 부분적으로 얹혀 있다. NVIDIA 실험은 에이전트별 원격 호출 1회 제약 때문에 full-game autonomous play보다 제한된 first-decision behavior에 가깝다. 정책 스크린은 model-policy cell당 24 표본이므로 보조 결과다.

English

Abstract

We evaluate fixed-policy LLM play in a reproducible four-player Go-Stop harness. Go-Stop compresses hidden information, stochastic draws, combinatorial scoring, multi-agent interaction, and risk-sensitive stop-or-continue decisions into short episodes. The main Qwen and NVIDIA panels show that observed performance is not explained by parameter scale alone. Supplementary screens show positive small-model results under restricted settings and model-specific policy-framing effects. The results are descriptive, not universal model rankings.

Why Go-Stop?

Go-Stop is a compact stochastic decision environment. Each action is chosen under hidden cards, uncertain future draws, opponent interaction, and settlement rules that can create heavy lower-tail losses. The Go/Stop decision is a risk-sensitive stopping problem.

Mean profit alone is not sufficient. The evaluation reports CVaR 5%, win rate, ruin probability, and sample count together.

Industrial Link: Advertising Bidding

Advertising bidding is not the same domain as Go-Stop, but the decision structure is similar enough to motivate the evaluation frame. An ad system repeatedly decides whether to bid, lower a bid, or wait under a finite budget. Conversion probability, competing bids, frequency fatigue, remaining budget, and campaign pacing are all uncertain.

A policy may show attractive average ROAS while spending too fast in specific segments, over-exposing low-quality inventory, or creating rare but severe losses. The Go-Stop harness does not simulate advertising directly; it supplies a compact stress test for sequential action selection, uncertainty, budget-risk trade-offs, and lower-tail risk control.

Research Questions and Answers

RQ1: Is Go-Stop a plausible environment for evaluating risk-sensitive sequential decision making by LLM agents? The answer is methodologically positive.

RQ2: Is observed performance monotone in nominal parameter scale in the Qwen-labeled DashScope panel? The answer is descriptively negative.

RQ3: Are cross-family differences visible in a rate-limited, roughly same-scale NVIDIA Build panel? They are visible under the constrained panel.

RQ4: Do small models and prompt-policy variants show measurable but model-specific differences? Exploratorily, yes.

Glossary

Mean profit: the average session-ending profit for a model. The mean alone does not capture severe downside risk.

CVaR 5%: the average of the worst 5% outcomes. In this paper it is descriptive, not confirmatory, because sample counts are small.

Win rate: the share of sessions with positive profit. A high win rate can still hide rare but severe losses.

Ruin probability: the probability that a player exhausts capital or reaches an effectively bankrupt state.

Parameter scale: the nominal parameter size of a model. For MoE models, total parameters and active parameters can differ.

Policy framing: the decision-making instruction style given to the model.

ROAS: Return on Ad Spend. A strong average ROAS can still hide budget burn or lower-tail loss risk.

Budget pacing: controlling campaign spend rate so the budget lasts across the intended time window.

Four Policy Framings in Plain Language

Balanced: the default frame. Consider profit and risk together. It is neither strongly cautious nor strongly risk-seeking.

Analytic: the evidence-focused frame. Reason more about combinations, expected value, and opponent risk.

Conservative: the loss-avoidance frame. Avoid large downside outcomes, stop earlier when uncertain, and preserve capital.

Aggressive: the upside-seeking frame. Push harder when a profitable chance appears and accept more risk for higher payoff.

Results

Model	Scale	Mean profit	CVaR 5%	Win rate	Samples
qwen3.5-397b-a17b	397B/A17B	996.25	-1850.08	0.3021	48
qwen3.5-122b-a10b	122B/A10B	-51.75	-4145.33	0.3542	48
qwen3-coder-480b-a35b-instruct	480B/A35B	-198.92	-5084.75	0.2396	48
qwen3-coder-30b-a3b-instruct	30B/A3B	-745.58	-5269.25	0.1042	48

Model	Scale	Mean profit	CVaR 5%	Win rate	Samples
nvidia/nemotron-3-super-120b-a12b	~120B	500.65	-1384.17	0.2708	48
mistralai/mistral-small-4-119b-2603	~119B	-73.19	-4150.00	0.2917	48
qwen/qwen3.5-122b-a10b	122B	-172.85	-3350.42	0.1875	48
stockmark/stockmark-2-100b-instruct	~100B	-254.60	-4267.08	0.2500	48

Small model	Scale	Mean profit	CVaR 5%	Win rate	Samples
ibm/granite-3.0-3b-a800m-instruct	3B/A800M	381.25	-1966.67	0.3125	48
meta/llama-3.2-1b-instruct	1B	-20.83	-2083.33	0.2708	48
google/gemma-2-2b-it	2B	-68.75	-3833.33	0.2500	48
microsoft/phi-4-mini-instruct	mini	-291.67	-3916.67	0.1667	48

Policy	Qwen top model	Top mean	Top CVaR
Balanced	qwen3-4b	224.88	-1166.67
Analytic	qwen3-4b	412.33	-2566.83
Conservative	qwen3-8b	238.08	-1301.67
Aggressive	qwen3-14b	254.08	-1284.33

Policy	NVIDIA top model	Top mean	Top CVaR
Balanced	nvidia/nemotron-3-super-120b-a12b	645.17	-2067.00
Analytic	nvidia/nemotron-3-super-120b-a12b	598.92	-2067.00
Conservative	nvidia/nemotron-3-super-120b-a12b	416.67	-1850.00
Aggressive	nvidia/nemotron-3-super-120b-a12b	598.83	-3701.67

Is This Study Meaningful?

Yes, but its meaning is specific. This is not a paper claiming that one model is universally the best Go-Stop player. It is better framed as an evaluation-harness and exploratory remote-model comparison study for sequential decision making, risk control, scale effects, family differences, and prompt-policy sensitivity.

The publishable contribution has three parts. First, Go-Stop is a compact benchmark with hidden information and lower-tail risk. Second, the Qwen panel is not monotone in nominal parameter scale. Third, the NVIDIA same-scale panel and policy screens show observable model-specific differences.

The weak points are also clear: sample counts are modest, the NVIDIA run uses a one-call constraint, and the Qwen scale comparison mixes Coder and Qwen3.5 variants. The claim should therefore be reproducible exploratory evaluation and methodological evidence, not definitive model ranking.

Limitations

The model panels are convenience samples from available remote APIs. The Qwen comparison mixes Coder and Qwen3.5 variants, so parameter scale is partly confounded with specialization. The NVIDIA run is constrained by one remote call per agent per session, so it measures constrained first-decision behavior more than full-game autonomous play. Policy screens have 24 samples per model-policy cell and are supplementary.

Reproducibility Commands

```
python3 scripts/run_dashscope_qwen_parameter_sweep.py \  
--session-hands 2 \  
--layout-repetitions 2 \  
--remote-eval-hands 2 \  
--decoding max_tokens=64 \  
--decoding temperature=0 \  
--decoding enable_thinking=false \  
--output-dir results/paper_qwen_4model_param_2h_2rep  
  
python3 scripts/run_nvidia_same_size_family_eval.py \  
--session-hands 1 \  
--layout-repetitions 2 \  
--remote-eval-hands 1 \  
--max-remote-calls-per-agent 1 \  
--decoding max_tokens=64 \  
--decoding temperature=0 \  
--output-dir results/paper_nvidia_120b_4model_family_1h_2rep_budget1
```